Témalaboratórium - BMEVITMBB04
1. Projektfeladat specifikáció

Gubicza Milán – KAIB9Y

"Okos utazástervező"

**1. Választott Dataset**:

A projekt során a Kaggle-ről származó *Flights* (NYC Flights 2013) adathalmazt fogom használni.
Ez több mint 300 000 belföldi járat adatait tartalmazza, amelyek 2013-ban indultak New York három fő repülőteréről (JFK, LGA, EWR).
A legfontosabb oszlopok a feladathoz: indulási és érkezési késések (dep_delay, arr_delay), légitársaság (carrier), célállomás (dest) és a pontos dátum/időpont.

| | A | B | C | D | E | F | G | H | I | J | K | L | M | N | O | P | Q | R | S | T | U |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | id | year | month | day | dep_time | sched_dep_t | dep_delay | arr_time | sched_arr_ti | arr_delay | carrier | flight | tailnum | origin | dest | air_time | distance | hour | minute | time_hour | name |
| 2 | 0 | 2013 | 1 | 1 | 517 | 515 | 2 | 830 | 819 | 11 | UA | 1545 | N14228 | EWR | IAH | 227 | 1400 | 5 | 15 | 1/1/13 5:00 | United Air Lines |
| 3 | 1 | 2013 | 1 | 1 | 533 | 529 | 4 | 850 | 830 | 20 | UA | 1714 | N24211 | LGA | IAH | 227 | 1416 | 5 | 29 | 1/1/13 5:00 | United Air Lines |
| 4 | 2 | 2013 | 1 | 1 | 542 | 540 | 2 | 923 | 850 | 33 | AA | 1141 | N619AA | JFK | MIA | 160 | 1089 | 5 | 40 | 1/1/13 5:00 | American Airline |
| 5 | 3 | 2013 | 1 | 1 | 544 | 545 | -1 | 1004 | 1022 | -18 | B6 | 725 | N804JB | JFK | BQN | 183 | 1576 | 5 | 45 | 1/1/13 5:00 | JetBlue Airways |
| 6 | 4 | 2013 | 1 | 1 | 554 | 600 | -6 | 812 | 837 | -25 | DL | 461 | N668DN | LGA | ATL | 116 | 762 | 6 | 0 | 1/1/13 6:00 | Delta Air Lines I |
| 7 | 5 | 2013 | 1 | 1 | 554 | 558 | -4 | 740 | 728 | 12 | UA | 1696 | N39463 | EWR | ORD | 150 | 719 | 5 | 58 | 1/1/13 5:00 | United Air Lines |
| 8 | 6 | 2013 | 1 | 1 | 555 | 600 | -5 | 913 | 854 | 19 | B6 | 507 | N516JB | EWR | FLL | 158 | 1065 | 6 | 0 | 1/1/13 6:00 | JetBlue Airways |
| 9 | 7 | 2013 | 1 | 1 | 557 | 600 | -3 | 709 | 723 | -14 | EV | 5708 | N829AS | LGA | IAD | 53 | 229 | 6 | 0 | 1/1/13 6:00 | ExpressJet Airlir |
| 10 | 8 | 2013 | 1 | 1 | 557 | 600 | -3 | 838 | 846 | -8 | B6 | 79 | N593JB | JFK | MCO | 140 | 944 | 6 | 0 | 1/1/13 6:00 | JetBlue Airways |
| 11 | 9 | 2013 | 1 | 1 | 558 | 600 | -2 | 753 | 745 | 8 | AA | 301 | N3ALAA | LGA | ORD | 138 | 733 | 6 | 0 | 1/1/13 6:00 | American Airline |
| 12 | 10 | 2013 | 1 | 1 | 558 | 600 | -2 | 849 | 851 | -2 | B6 | 49 | N793JB | JFK | PBI | 149 | 1028 | 6 | 0 | 1/1/13 6:00 | JetBlue Airways |
| 13 | 11 | 2013 | 1 | 1 | 558 | 600 | -2 | 853 | 856 | -3 | B6 | 71 | N657JB | JFK | TPA | 158 | 1005 | 6 | 0 | 1/1/13 6:00 | JetBlue Airways |
| 14 | 12 | 2013 | 1 | 1 | 558 | 600 | -2 | 924 | 917 | 7 | UA | 194 | N29129 | JFK | LAX | 345 | 2475 | 6 | 0 | 1/1/13 6:00 | United Air Lines |
| 15 | 13 | 2013 | 1 | 1 | 558 | 600 | -2 | 923 | 937 | -14 | UA | 1124 | N53441 | EWR | SFO | 361 | 2565 | 6 | 0 | 1/1/13 6:00 | United Air Lines |
| 16 | 14 | 2013 | 1 | 1 | 559 | 600 | -1 | 941 | 910 | 31 | AA | 707 | N3DUAA | LGA | DFW | 257 | 1389 | 6 | 0 | 1/1/13 6:00 | American Airline |
| 17 | 15 | 2013 | 1 | 1 | 559 | 559 | 0 | 702 | 706 | -4 | B6 | 1806 | N708JB | JFK | BOS | 44 | 187 | 5 | 59 | 1/1/13 5:00 | JetBlue Airways |
| 18 | 16 | 2013 | 1 | 1 | 559 | 600 | -1 | 854 | 902 | -8 | UA | 1187 | N76515 | EWR | LAS | 337 | 2227 | 6 | 0 | 1/1/13 6:00 | United Air Lines |
| 19 | 17 | 2013 | 1 | 1 | 600 | 600 | 0 | 851 | 858 | -7 | B6 | 371 | N595JB | LGA | FLL | 152 | 1076 | 6 | 0 | 1/1/13 6:00 | JetBlue Airways |
| 20 | 18 | 2013 | 1 | 1 | 600 | 600 | 0 | 837 | 825 | 12 | MQ | 4650 | N542MQ | LGA | ATL | 134 | 762 | 6 | 0 | 1/1/13 6:00 | Envoy Air |

**2. A probléma:**

Amikor egy átlagember vagy egy üzleti utazó repülőjegyet keres (pl. Skyscanneren), a rendszerek jellemzően csak az árat és az utazási időt mutatják. Egy szoros átszállásnál vagy fontos találkozónál azonban a legkritikusabb faktor a **megbízhatóság**. Hiába tűnik jónak egy esti járat, ha az adatok alapján az esetek 40%-ában legalább fél órát késik. Jelenleg a felhasználók "vakon" választanak a járatok között a késési kockázat ismerete nélkül.

**3. Az ötlet és a megoldás**:

Célom egy utasközpontú, adatalapú döntéstámogató “modul” elkészítése. A program bemenetként várja az indulási és érkezési célpontot (pl. JFK -> LAX). Kimenetként nem a legolcsóbb, hanem a legmegbízhatóbb opciókat adja vissza: megmutatja, hogy az adott útvonalon melyik légitársaságot és melyik napszakot érdemes választani a késés minimalizálása érdekében.

**4. Technikai megvalósítás (Python, Pandas, Numpy)**:

A projekt megvalósítása az alábbi lépésekből áll:

- **Adattisztítás:**
  A nyers adatokból új, hasznos változókat állítok elő.
  A year, month, day és hour adatokból datetime objektumokat képzek, majd ezek alapján kategorizálom a járatokat napszakok szerint (pl. hajnal, délelőtt, délután, este). Kezelem a hiányzó adatokat (törölt járatok).

- **Kockázati metrikák számítása:**
  Nem csak az átlagos késést számolom ki, hanem bevezetek egy "Megbízhatósági indexet". Numpy segítségével kiszámolom a késési valószínűséget: (15 percnél többet késő járatok száma) / (összes járat száma) (ez még változhat, csak egy ötlet) az adott útvonalra és időszakra vetítve.

- **Aggregáció:** A végleges ajánlórendszer a .groupby(['origin', 'dest', 'carrier', 'napszak']) függvényekkel aggregálja az adatokat, majd rendezi azokat a legkisebb kockázatú opcióktól a legrosszabbak felé.

**5. Példa az elvárt működésre**:
Ha a felhasználó megadja a JFK (New York) -> LAX (Los Angeles) útvonalat, a program egy ehhez hasonló aggregált ranglistát ad vissza:

1. Javasolt: Delta Airlines (DL) – Délelőtti járatok. (Késési esély: 12%, Átlagos késés: 5 perc)
2. Elfogadható: American Airlines (AA) – Reggeli járatok. (Késési esély: 18%, Átlagos késés: 11 perc)
3. Kockázatos: United Airlines (UA) – Esti járatok. (Késési esély: 42%, Átlagos késés: 35 perc)

Így az utazó már egy egyértelmű, adatokkal alátámasztott kockázati profil alapján tudja megvenni a jegyét.

Szívesen várom a Tanár Úr egyéb észrevételeit, ötleteit a választott témához.